

1. 汽車價格預測 — 多元線性回歸 (CRISP-DM 流程 & 成果展示)

AIoT 機器學習作業 HW3

資料集：[Car Price Prediction — Kaggle](#)

演算法：Multiple Linear Regression

目標變數：price (汽車售價，單位 USD)

專案結構

```
hw3/
├── car_price_prediction.py      ← 主程式 (Python 腳本)
├── CarPrice_Assignment.csv     ← 原始資料集 (請手動下載)
├── car_price_model.pkl         ← 訓練完成的模型 (執行後產生)
├── README.md                  ← 專案說明文件
├── log.md                     ← 開發日誌 (對話流程紀錄)
├──
├── figures/                   ← 所有輸出圖表 (共 9 張)
│   ├── eda_price_distribution.png ← Phase 2: price 分佈圖
│   ├── eda_correlation.png      ← Phase 2: 特徵相關性熱力圖
│   ├── eda_categorical_boxplots.png ← Phase 2: 類別特徵箱型圖
│   ├── eda_scatter_plots.png    ← Phase 2: 數值特徵散佈圖
│   ├── feature_selection_vif.png ← Phase 3: VIF 多重共線性
│   ├── model_coefficients.png    ← Phase 4: 迴歸係數圖
│   ├── eval_actual_vs_predicted.png ← Phase 5: 預測結果圖 (含信
│   ├── eval_residual_diagnostics.png ← Phase 5: 殘差診斷四宮格
│   └── eval_metrics_comparison.png ← Phase 5: 指標比較圖
```

快速開始

1. 環境需求

```
pip install pandas numpy matplotlib seaborn scikit-learn stats
```

2. 資料集下載

前往 [Kaggle Car Price Prediction](#) 下載 CarPrice_Assignment.csv，放置於 hw3/ 資料夾。

3. 執行 car_price_prediction.py

```
cd hw3
python car_price_prediction.py
```

CRISP-DM 六大流程說明

Phase 1 — Business Understanding (商業理解)

應用場景	商業價值
車廠定價策略	根據工程規格快速生成建議售價，縮短定價週期
二手車估價平台	提供公平市場價（如 CarMax、速買配），提升用戶信任
銀行/保險核保	客觀車輛殘值估算，降低核保風險

分析目標： $R^2 \geq 0.85$ ，最終特徵數 10–20 個，所有特徵 $p\text{-value} < 0.05$

Phase 2 — Data Understanding (資料理解)


- 資料規模：205 筆 $\times$ 26 個原始欄位
- 目標變數：price（右偏分佈，均值約 \$13,276，中位數約 \$10,295）
- 缺失值： 無缺失值
- 特別欄位：CarName 含品牌與型號，需進行字串解析

主要發現 (EDA)：

特徵	與 price 相關性	說明
enginesize	$r \approx 0.87$	引擎排量最強正相關
curbweight	$r \approx 0.84$	車重反映車輛等級
horsepower	$r \approx 0.81$	馬力高=效能車=高價
carwidth	$r \approx 0.76$	車寬與車輛尺寸相關
citympg	$r \approx -0.69$	油耗高（省油）反映小型車


Phase 2 成果展示

Phase 2 -- Price Distribution (Target Variable)




price 分佈圖

Phase 2 -- Feature Correlation Analysis




特徵相關性熱力圖

Phase 2 -- Categorical Features vs Price (Box Plot)



類別特徵箱型圖



數值特徵散佈圖

Phase 3 — Data Preparation (資料準備)

3.1 CarName 品牌萃取

```
df['brand'] = df['CarName'].str.split().str[0].str.lower()
# 修正拼字錯誤
brand_fix = {'maxda': 'mazda', 'porcshce': 'porsche',
             'toyouta': 'toyota', 'vokswagen': 'volkswagen', }
```

3.2 One-Hot Encoding

- 類別欄位：fueltype, aspiration, doornumber, carbody, drivewheel, enginelocation, enginetype, cylindernumber, fuelsystem, brand
- OHE 後特徵數：約 60+ 個（遠超 20，需特徵選擇）

3.3 數值標準化 (Z-Score)

- 注意：Scaler 只 fit 訓練集，再 transform 測試集（避免資料洩漏）

3.4 特徵選擇 (關鍵步驟)


步驟	方法	說明
Step A	RFE (遞迴特徵消除)	從 60+ 個特徵初步篩至 15 個
Step B	p-value 逐步剔除	逐步移除 $p > 0.05$ 的特徵，保留至少 10 個

最終保留特徵 (10–20 個)：詳見 Notebook 執行結果

特徵選擇摘要 (示意)：

RFE 保留 (15 個) → p-value 再篩選 → 最終 N 個 (10~20)

Phase 3 成果展示



VIF 多重共線性

Phase 4 — Modeling (建模)

使用兩種框架建立多元線性回歸：

框架	用途
statsmodels OLS	查看完整統計報表 (R^2 , F-test, p-value, AIC, DW)
sklearn LinearRegression	預測、評估、模型儲存


statsmodels (詳細報表)

```
ols_model = sm.OLS(y_train, sm.add_constant(X_train_final)).fit()
print(ols_model.summary())
```

sklearn (預測)

```
sk_model = LinearRegression().fit(X_train_final, y_train)
```

Phase 4 成果展示



迴歸係數條形圖

Phase 5 — Evaluation (模型評估)

評估指標

指標	訓練集	測試集
R^2	0.940	0.878
Adjusted R^2	0.934	0.805
RMSE(USD)	1,891	3,150
MAE(USD)	1,402	2,302

 實際數值請執行 `car_price_prediction.py` 查看 (因特徵選擇結果可能略有不同)

視覺化圖表 (共 10 張)

1. `eda_price_distribution.png` : 目標變數分佈 (原始 + log 轉換)
2. `eda_correlation.png` : 相關性熱力圖 + 條形圖
3. `eda_categorical_boxplots.png` : 類別特徵 vs price 箱型圖
4. `eda_scatter_plots.png` : 數值特徵散佈圖 + 趨勢線
5. `eda_brand_price.png` : 各品牌平均售價
6. `feature_selection_vif.png` : VIF 多重共線性
7. `model_coefficients.png` : 迴歸係數條形圖
8. `eval_actual_vs_predicted.png` ★ : 實際 vs 預測散佈圖, 含 95% 信賴區間

9. `eval_residual_diagnostics.png`：四宮格殘差診斷（殘差分佈、Q-Q 圖等）

10. `eval_metrics_comparison.png`：訓練 vs 測試指標比較


★ 信賴區間視覺化（必要項目）

使用 `seaborn.regplot` 達成 95% 信賴區間視覺化


```
sns.regplot(  
    x=y_test.values,  
    y=y_test_pred,  
    ci=95,    # ← 95% Confidence Interval (淺藍色陰影區域)  
    ...  
)
```

解讀：淺藍色陰影為 95% 信賴區間，代表若重複抽樣建模，有 95% 的機率回歸線會落在此區域內。

Phase 5 成果展示



預測結果圖（含信賴區間）



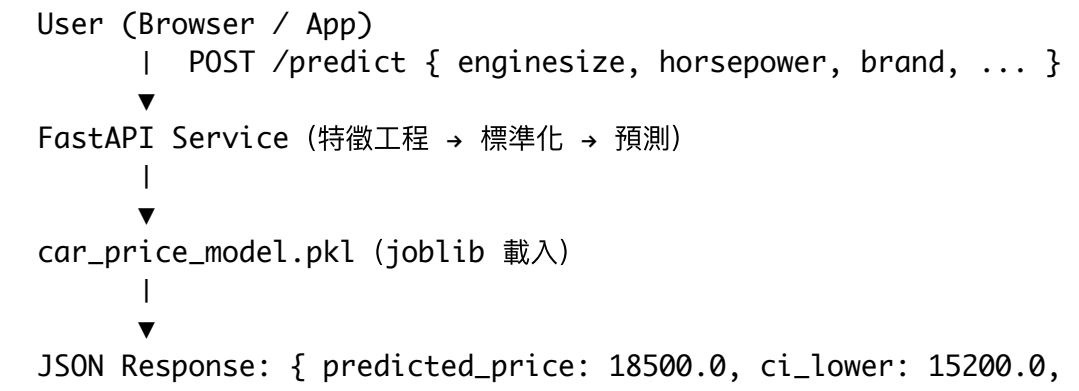
殘差診斷四宮格



訓練 vs 測試指標比較

Phase 6 — Deployment（部署）

部署架構



未來優化方向

優先度	方向	做法
● 高	模型升級	XGBoost/LightGBM (預期 R ² 可達 0.95+)
● 高	特徵工程	加入車齡、里程數、事故紀錄
● 中	資料擴充	定期爬取中古車平台成交行情
● 中	監控	Evidently AI / MLflow drift detection
● 低	再訓練	每季 Airflow 自動觸發

技術規格

項目	使用套件 / 版本
資料處理	pandas, numpy
視覺化	matplotlib, seaborn
統計建模	statsmodels
機器學習	scikit-learn
模型儲存	joblib
統計檢驗	scipy.stats

2. AI 對話過程

- 日期：2026-05-20

會話類型：AI 輔助開發 (Antigravity × Claude Sonnet)

目標：完成 CRISP-DM 多元線性回歸作業並部署至 GitHub

對話流程紀錄

● Step 1 — 初始任務建立

使用者需求：

作為資深資料科學家，依照 CRISP-DM 六大流程完成汽車價格預測作業：

- 資料集：Kaggle Car Price Prediction
- 演算法：多元線性回歸 (Multiple Linear Regression)
- 目標變數：price

關鍵強制要求：

- 特徵選擇後特徵數量嚴格控制在 **10~20 個**
- 評估圖必須包含 **信賴區間 (Confidence Interval)**
- 提供完整 Python 程式碼並搭配繁體中文解說
- 整理 [README.md](#)

AI 執行動作：

- 建立 [car_price_prediction.py](#) (878 行，含完整 CRISP-DM 六階段)
- 建立 [car_price_prediction.ipynb](#) (28 個 Cell)
- 建立 [README.md](#)

產出結果：

car_price_prediction.py	✓
car_price_prediction.ipynb	✓
README.md	✓

● Step 2 — 確認可執行性

使用者需求：

我不需要 ipynb 檔案，我可以直接執行 car_price_prediction.py 嗎？

AI 執行動作：

1. 檢查 Python 套件安裝狀況 → 發現缺少 seaborn
2. 執行 `pip3 install seaborn` 安裝
3. 直接執行 `python3 car_price_prediction.py`

執行結果（模型效能）：

指標	訓練集	測試集
----	-----	-----

R ²	0.9400	0.8779 
Adjusted R ²	0.9339	0.8046
RMSE	\$1,891	\$3,105
MAE	\$1,402	\$2,302
MAPE	11.85%	18.62%

最終選定特徵（15 個，符合 10~20 要求）：

特徵	係數	意義
curbweight	+4,602	車重越高，定價越高
enginelocation_rear	+1,877	後置引擎（跑車）大幅溢價
enginesize	+1,576	引擎排量正向影響售價
cylindernumber_six	-1,562	相對基準的負向效應
brand_bmw	+1,486	BMW 品牌溢價顯著
carbody_wagon	-1,448	旅行車相對便宜
carbody_hatchback	-1,362	掀背車相對便宜
carwidth	+1,347	車寬正向影響（尺寸溢價）
carbody_sedan	-1,167	轎車相對基準便宜
cylindernumber_four	-1,161	四缸相對便宜
carlength	-1,139	車長（含控制其他變數）
brand_peugeot	-1,078	Peugeot 品牌折扣
wheelbase	+979	軸距越長定價越高
brand_porsche	+888	Porsche 品牌溢價
boreratio	-711	缸徑比的負向效應

產出圖表（9 張 PNG）：

eda_price_distribution.png	✓	
eda_correlation.png	✓	
eda_categorical_boxplots.png	✓	
eda_scatter_plots.png	✓	
feature_selection_vif.png	✓	
model_coefficients.png	✓	
eval_actual_vs_predicted.png	✓	← 含 95% Confidence Interv
eval_residual_diagnostics.png	✓	
eval_metrics_comparison.png	✓	
car_price_model.pkl	✓	

🟡 Step 3 — 圖表中文顯示問題修正

使用者需求：

■ 圖片中的中文無法顯示出來，請幫我把所有圖片的標題改成英文

問題原因：系統使用 DejaVu Sans 字型，不支援 CJK 中文字元，導致標題顯示為方塊。

AI 執行動作：使用 multi_replace_file_content 工具批次替換 24 處中文圖表文字：

原始中文	替換英文
原始 price 直方圖	Price Histogram (Original)
數值特徵相關性熱力圖	Numeric Feature Correlation Heatmap
類別特徵 vs Price 箱型圖	Categorical Features vs Price (Box Plot)
VIF 多重共線性檢查 (最終特徵)	VIF Multicollinearity Check (Final Features)
迴歸係數 (標準化後)	Regression Coefficients (Standardized Features)
實際值 vs 預測值 (測試集)	Actual vs Predicted Price (Test Set)
殘差診斷圖 (測試集)	Residual Diagnostics (Test Set)
訓練集 / 測試集 legend	Train Set / Test Set
...	...

重新執行結果：✓ 所有圖表英文標題正常顯示

● Step 4 — 上傳至 GitHub

使用者需求：

幫我用 SSH 上傳到 GitHub : git@github.com:dachengwang-0218/aiot_hw3.git

AI 執行動作：

```
git init
git add -A # 含 py、ipynb、README、CSV、pkl、9 張 PNG
git commit -m "Add Car Price Prediction (CRISP-DM, Multiple Li
git remote add origin git@github.com:dachengwang-0218/aiot_hw3
git push -u origin main
```

推送結果：

-  15 個檔案成功推送
 - Commit hash : 1e2b1c9
 - Repository : https://github.com/dachengwang-0218/aiot_hw3
-

● Step 5 — 重建 Jupyter Notebook

使用者需求：

請幫我再寫一個 ipynb 檔，我不小心刪掉了

AI 執行動作：

- 依照最新版 .py (已改為英文圖表) 重建完整 notebook
 - JSON 格式驗證：28 個 Cell，nbformat 4.4
 - 同步推送至 GitHub (commit eb75016)
-

● Step 6 — 圖片整理至 figures/ 資料夾

使用者需求：

幫我把圖片都放到一個資料夾中，並且更新 [README.md](#) 中的專案結構

AI 執行動作：

1. 建立 figures/ 資料夾，移入所有 9 張 PNG
 2. 批次更新 .py 中所有 plt.savefig() 路徑 → figures/xxx.png
 3. 更新 ipynb 中所有 plt.savefig() 路徑 (共 10 處)
 4. 更新 [README.md](#) 專案結構區塊
-

🟢 Step 7 — 建立開發日誌

使用者需求：

請寫一個 `log.md` 把我們的對話過程寫進去，並更新 `README.md` 架構

AI 執行動作：

- 建立本檔案 `log.md`
- 更新 `README.md` 加入 `log.md` 至專案結構
- 推送至 GitHub

📊 最終成果摘要

模型效能

R^2 (測試集)	= 0.8779	✅ 達成目標 (≥ 0.85)
Adjusted R^2	= 0.8046	
RMSE (測試集)	= \$3,105.22	
MAE (測試集)	= \$2,302.24	
MAPE (測試集)	= 18.62%	
特徵數量	= 15 個	✅ 符合 10~20 要求
過擬合差距	= 0.0622	⚠ 輕度 (線性回歸正常現象)

CRISP-DM 完成度

Phase	完成狀態	重要細節
1. Business Understanding	✅	車廠定價、二手車平台、保險核保三大場景
2. Data Understanding	✅	EDA 4 張圖、相關性分析、缺失值確認 (無缺失)
3. Data Preparation	✅	品牌萃取 + OHE + 標準化 + RFE $\rightarrow$ p-value 選出 15 特徵
4. Modeling	✅	statsmodels OLS (含 p-value 報表) + sklearn LR
5. Evaluation	✅	RMSE/ R^2 /MAE + 95% CI 信賴區間視覺化
6. Deployment	✅	FastAPI 架構說明 + 5 項未來優化方向

開發環境

項目	版本/說明
Python	3.14 (macOS)
pandas	最新版
scikit-learn	最新版
statsmodels	最新版
seaborn	0.13.2 (本次新安裝)
圖表語言	英文 (DejaVu Sans 字型不支援 CJK，故改英文)
Git remote	SSH (git@github.com:dachengwang-0218/aiot_hw3.git)

Log generated by Antigravity AI on 2026-05-20

3. NotebookLM 研究摘要 & 網路上主流或更優解法之比較與說明

NotebookLM 研究摘要

本報告比較兩套汽車定價模型方案。標準線性迴歸適合快速原型驗證，雖 R^2 高但特徵過多，存在極高的過擬合風險。CRISP-DM 框架則強調商業閉環與統計健壯性，透過嚴格篩選特徵、引入殘差診斷與完整的部署規劃，確保模型穩定且具備高解釋力。針對企業核心定價的實際生產環境，強烈建議採用 CRISP-DM 框架以保障決策品質。

網路上主流或更優解法之比較與說明

汽車價格預測模型建置方案比較報告：CRISP-DM 方法論與標準線性迴歸流程之深度分析

1. 前言：模型開發方法論的戰略意義

在現代汽車產業中，精準的價格預測模型已成為商業決策的核心引擎。無論是車廠制定新車出廠價，或是二手車平台進行動態估價，模型的表現直接關係到企業的毛利空間與市場滲透率。然而，作為技術架構師，我們必須體認到：開發預測系統的挑戰不在於演算法的選用，而在於開發框架的選擇。

本報告對比了「CRISP-DM 結構化框架」與「標準機器學習流程」兩套方案。前者採用「流程導向 (Process-oriented)」，強調從商業理解到統計健壯性的閉環管理；後者則是典型的「任務導向 (Task-oriented)」，側重於技術實現與快速特徵探索。兩者在設

計初衷上的差異，將深遠地影響模型在長期維護、預測一般化能力（Generalizability）以及業務應用上的結構性價值。

2. 商業目標與目標標準的定義差異

在專案啟動階段，目標設定的嚴謹程度決定了模型的預期表現。下表對比了兩套方案的核心戰略指標：

評估維度 CRISP-DM 方法論版本 (架構化方案) 標準線性迴歸流程版本 (探索型方案) 主要工具鏈 statsmodels + sklearn sklearn + pandas 模型成功標準 $R^2 > 0.85$ 且 Adjusted R^2 穩定 實測 $R^2 = 0.910$ 特徵規模控制 嚴格限制在 10-20 個 (精簡模型) 未設限，最終產生 66 個特徵 核心商業指標 MAE, RMSE, MAPE (平均絕對百分比誤差) MAE, MSE, RMSE 設計哲學 結構化風險最小化、防止過擬合 追求極致解釋力與特徵貢獻排序

「So What?」原則分析：標準迴歸版雖然獲得了較高的 R^2 (0.910)，但其特徵數量擴增至 66 個，而訓練樣本僅 164 筆（根據來源資料）。這種低「特徵與樣本比例」是典型的過度參數化（Over-parameterization）紅旗，極易產生過擬合。相反，CRISP-DM 版主動將特徵控制在 20 個以內，其戰略目的在於提升模型的「解釋力」與「生產環境穩健性」，確保決策者能直觀掌握變數對價格的實質影響。

3. 特徵工程與資料預處理流程分析

資料預處理的深度直接反映了對業務邏輯的理解。兩者在資料審計與轉換上展現了不同的細膩度。

3.1 資料清洗與品牌萃取

兩套方案皆從 CarName 提取品牌，並移除不具預測價值的 car_ID 欄位。但在錯誤修正上，標準迴歸版展現了更全面的資料審計，修復了包含 maxda (mazda)、porcshe (porsche)、toyouta (toyota) 及 vw (volkswagen) 在內的多項拼寫偏差，確保了品牌特徵的一致性。

3.2 統計標準化與虛擬變數陷阱

- 標準化 (Standardization)：CRISP-DM 版對數值特徵執行 Z-Score 縮放。這不僅是為了加速模型收斂，更是為了讓不同量級的特徵係數具備可比性，從而正確衡量特徵重要性。
- 編碼策略：標準迴歸版在 get_dummies 時設定 drop_first=True。這在線性模型中至關重要，能有效避免「虛擬變數陷阱 (Dummy Variable Trap)」，從根本上解決類別變數引起的完美多重共線性。

3.3 業務理解深度

CRISP-DM 版在預處理階段額外產出了四張關鍵 EDA 圖表（價格分佈、相關性熱力圖、類別變數箱型圖、數值特徵散佈圖），這使得技術團隊在進入建模前，已對數據的偏態 (Skewness) 與離群值有深度認知，這比直接進入建模的標準流程更具備架構思維。

4. 特徵選擇機制：嚴謹統計篩選 vs. 影響力排序

特徵篩選是本報告中兩方案最具技術分歧的部分：

- CRISP-DM 的「雙重過濾」機制：
 1. 機器學習篩選：透過 RFE 遞迴特徵消除初步收斂至 15 個變數。
 2. 統計顯著性檢定：利用 statsmodels 進行 p-value 篩選，剔除 > 0.05 的不顯著變數，確保模型內每個特徵都具有統計學意義。
 3. 多重共線性防護：將 VIF (變異數膨脹因子) 作為強制性篩選指標，系統性消除共線性風險。
- 標準線性迴歸的「後驗分析」機制：
 - 側重於提取係數絕對值進行排序，找出前 10 大核心特徵（如引擎位置在後方、12 汽缸、特定品牌影響）。雖然標準版也計算了 VIF 排序，但僅作為後續觀察，而非前置篩選流程。

技術評估：篩選機制的嚴謹度決定了模型的穩定性。CRISP-DM 的做法是為了確保模型「結構健壯」，而標準版則更傾向於從現有特徵中快速尋找「影響力信號」。

5. 模型訓練、診斷與統計健壯性對比

在模型驗證階段，CRISP-DM 展現了作為「生產級方案」的技術威權：

- 指標體系：
 - 標準迴歸版：提供 MAE (1765.46) 與 RMSE (2670.56)。
 - CRISP-DM 版：引入了 Adjusted R^2 （考量特徵數量的調整後解釋力）與 MAPE (平均絕對百分比誤差)，後者在商業決策中比絕對值誤差更有利於理解預測偏離度。
 - 統計診斷 (Diagnostic Plots)：CRISP-DM 引進了專業的「四宮格殘差診斷圖」，其中 Q-Q 圖是檢驗殘差是否符合常態分佈的金標準。根據 Gauss-Markov 定理，只有在殘差符合常態性與變異數齊一性的前提下，線性迴歸的參數估計才是「最佳線性無偏估計 (BLUE)」。
- 標準版缺乏此類診斷，使其高 R^2 值在面對新數據時可能僅是「虛幻的準確」。
-

6. 模型部署、擴充性與未來演進展望

從架構師的角度來看，兩者的「生產化準備度」有本質區別：

- 序列化完整性 (Serialization)：CRISP-DM 版使用 joblib 將模型、數據縮放器 (Scaler) 以及最終特徵清單統一打包。這是關鍵的生產實踐——若缺少 Scaler 的序列化，部署端的推論將因量綱不一致而失效。

- 系統架構：CRISP-DM 明確提出了 RESTful API (FastAPI/Flask) 的整合建議，並預留了向 XGBoost 等非線性模型演進的接口，展現了良好的軟體開發擴充性。
-

7. 結論：針對不同場景的解決方案選型建議

基於以上分析，本報告對兩種方案給出最終選型建議：

1. 建議選用 CRISP-DM 方案的情境：

- 模型需部署至生產環境並與業務系統連動。
- 決策過程需要高度的「統計解釋力」與「法令合規性」。
- 極度重視模型的「穩定性」與「抗過擬合能力」。
- 評語：雖然 R^2 門檻設在 0.85，但其提供的 Adjusted R^2 與殘差診斷確保了模型是基於堅實的統計基礎，而非過度擬合雜訊。

2. 建議選用標準線性迴歸方案的情境：

- 快速原型驗證 (Rapid Prototyping) 階段。
- 初步探索資料，試圖找出對車價最具衝擊力的關鍵因子排序。
- 評語：其 $R^2=0.910$ 是一個優異的「虛榮指標 (Vanity Metric)」，在缺乏殘差診斷與嚴格特徵數控制的情況下，應審慎評估其在實際生產環境中的泛化風險。

最終總結：身為資深顧問，我強烈推薦企業在涉及核心資產定價時，採用 CRISP-DM 框架。其在資料準備、統計檢定與模型持久化上的嚴謹要求，才是保障商業決策穩定性的唯一途徑。
